

Análisis de fallas en máquinas de costura para optimizar el mantenimiento industrial

Andrey Ismagilov

Barcelona Activa (IT Academy)

Bootcamp Data Analytics

Mentor: Yunier Córdova Cobas

Fecha: 19 de marzo de 2026

Resumen

Este estudio analiza registros históricos de fallas en máquinas de costura con el objetivo de identificar sus principales causas, reducir los tiempos de inactividad y optimizar la toma de decisiones en mantenimiento.

Para ello, se unieron tres datasets: datos de fallas y tiempos de paro del Sistema EAM, información de antigüedad de mecánicos de Recursos Humanos y un registro técnico con la edad de las máquinas.

La metodología incluyó integración y limpieza de datos, imputación de valores faltantes, EDA, análisis de Pareto, detección de valores atípicos en el tiempo de paro y cálculo de indicadores de mantenimiento como MTBF y MTTR.

Los resultados muestran una alta concentración de fallas en pocas categorías de problemas y tipo de fallas, especialmente en problemas asociados al cabezal de la máquina, que reúnen gran parte de las incidencias y del tiempo de paro.

Las variaciones en los tiempos de inactividad explican una parte significativa del impacto en la actividad operativa. Los KPIs de MTBF y MTTR demuestran mejoras progresivas en la fiabilidad y el mantenimiento de máquinas de costura durante el período analizado.

Además, los modelos más antiguos tienden a presentar tiempos de inactividad más prolongados y mayores costos de repuestos, lo que indica un posible efecto de obsolescencia. Por lo tanto, el análisis de los datos históricos de mantenimiento permite priorizar, optimizar los recursos y respaldar las decisiones técnicas relativas a las intervenciones, el monitoreo y las actualizaciones de los equipos.

Introducción

En entornos industriales, la disponibilidad y confiabilidad de los equipos son factores principales para la continuidad operativa, el cumplimiento de la producción y el control de costes. En el caso de las máquinas de costura industriales, las fallas imprevistas generan tiempos de paro, aumentan los costes de reparación y afectan el rendimiento del sistema productivo.

Es decir, las observaciones históricas de mantenimiento constituyen una fuente estratégica de información para transformar una gestión reactiva en una gestión basada en evidencia. El análisis de estos datos permite identificar qué fallas ocurren con mayor frecuencia, qué equipos concentran mayor impacto operativo y cómo evoluciona el desempeño del mantenimiento a lo largo del tiempo.

Este estudio analiza el problema de identificar las fallas más críticas del sistema, los modelos de máquinas que más contribuyen al tiempo de inactividad y la eficacia del mantenimiento en términos de confiabilidad y mantenibilidad. Además, se busca determinar si variables como la antigüedad de la máquina y el personal de mantenimiento pueden estar asociadas con diferencias en el rendimiento operativo.

El objetivo general fue analizar los datos históricos de fallas de máquinas de costura para identificar patrones relevantes y evaluar el comportamiento del mantenimiento industrial.

Como objetivos específicos se plantearon: unificar las fuentes de información disponibles, describir la distribución y evolución temporal de las fallas, aplicar análisis de Pareto para priorizar problemas, detectar valores atípicos en el tiempo de paro, calcular indicadores MTBF y MTTR, e investigar la posible relación entre antigüedad de máquinas, tiempos de espera y costes de mantenimiento.

Metodología

Diseño de la investigación

El estudio empleó un enfoque cuantitativo, descriptivo y analítico basado en datos históricos de mantenimiento. Se utilizaron datos de observación de sistemas de gestión internos.

Datos

La base principal provino del Sistema EAM, que contenía aproximadamente 150,000 órdenes de trabajo relacionadas con fallas de máquinas de costura. Las variables disponibles son identificador del equipo, operación, tipo de orden de trabajo, modelo base, códigos y descripciones de problema, códigos y descripciones de falla, códigos y descripciones de causa, códigos y descripciones de acción, nombre del mecánico, fecha, número de orden de trabajo, tiempo de paro bruto, horas de cobertura de máquina de respaldo, tiempo real de paro, coste de piezas, horas de reparación y horas de espera.

A esta base se integraron dos datasets adicionales. La primera fue del RRHH e incluía información sobre los mecánicos, particularmente su antigüedad laboral. La segunda tenía la edad de las máquinas de costura, utilizada como variable explicativa en el análisis de obsolescencia.

Preparación e integración de datos

Las tres fuentes se integraron a partir de variables clave, como el identificador de máquina y la identificación del mecánico asociado a cada orden de trabajo. Posteriormente, se realizó una fase de limpieza que incluyó revisión de tipos de datos, estandarización de categorías, detección de duplicados y tratamiento de valores faltantes.

Para la imputación de datos faltantes en variables numéricas se utilizó KNNImputer de la librería Scikit-learn. Las variables categóricas fueron depuradas y, cuando fue necesario, agrupadas en categorías operativas más manejables para facilitar el análisis.

Herramientas utilizadas

El análisis se desarrolló en Python. Se empleó Pandas para la manipulación y transformación de datos, Scikit-learn para imputación y preprocesamiento, y Matplotlib, Seaborn y Plotly Express para la visualización de resultados.

Técnicas de análisis

Se aplicaron cuatro bloques principales de análisis:

1. Análisis exploratorio de datos (EDA).

Se examinó la distribución de fallas por modelo, por tipo de orden de trabajo, por grupos de problema y por periodo temporal.

2. Análisis de Pareto.

Se identificaron las categorías de fallas y los modelos que concentraban la mayor parte de las incidencias y del tiempo de paro.

3. Detección de outliers en tiempo de paro.


Se evaluó la distribución de downtime_gross y se detectaron valores atípicos mediante el rango intercuartílico (IQR), con el objetivo de medir su efecto sobre el tiempo total de paro.

4. KPIs de mantenimiento.

Se calcularon los indicadores MTBF y MTTR. El MTTR se define como una medida de mantenibilidad equivalente al tiempo promedio de reparación; la documentación técnica de IEEE también recoge MTBF/MTTF dentro de las métricas básicas de confiabilidad.


Resultados

El análisis exploratorio mostró que un conjunto reducido de modelos base concentraba una proporción importante de los registros de falla. Entre ellos destacaron VC2700, FD62, VC1700 y VC2713.




En cuanto al tipo de orden de trabajo, predominó ampliamente el mantenimiento correctivo, con alrededor del 92.4% de los registros, mientras que el mantenimiento preventivo fue marginal.

Tipo de orden de trabajo




En la evolución temporal, tanto el número de fallas por mes como el tiempo de paro mensual mostraron una tendencia descendente a lo largo del período analizado. Los valores más altos se registraron en 2023, mientras que en 2024 se observó un comportamiento más estable y con menor impacto operativo.


Número de fallas por mes




Tiempo de paro por mes, horas



El análisis por grupos de problema reveló una fuerte concentración. La categoría “Cose con defecto” representó el 68.0% de las fallas, “No cose” el 25.6% y el grupo “Otros” el 6.4%.




En términos de tiempo de paro, “Cose con defecto” explicó el 76.3% del total, “No cose” el 17.9% y “Otros” el 5.8%.




En el Pareto de fallas específicas, las tres primeras categorías concentraron aproximadamente el 84% del total de fallas. Entre ellas destacaron las fallas del cabezal dejando de coser, las fallas del cabezal cosiendo con defecto y la falla del dispositivo de corte de desperdicio.

Análisis de Pareto por tipo de fallo




El análisis por modelos mostró que algunos equipos combinaban una alta cantidad de máquinas con una elevada suma de horas en outliers. Los modelos VC1700, VC2700, VC2713 y

FD62 destacaron por su criticidad relativa. Asimismo, el análisis acumulado evidenció un comportamiento tipo cola larga, donde pocos modelos explicaban una proporción elevada del impacto total de los eventos extremos.



En relación con los KPIs de mantenimiento, el MTBF mostró una evolución creciente, pasando de aproximadamente 1.4 días a valores cercanos a 27–31 días entre fallas. Por su parte, el MTTR descendió desde valores próximos a 1.8 horas hasta situarse en torno a 1.2–1.4 horas.



Finalmente, en el análisis de obsolescencia se observó que varios de los modelos más antiguos tendían a concentrar mayores horas de espera y mayores costes de piezas. Entre los modelos con mayor impacto en estas variables volvieron a destacar VC2700, FD62, VC1700 y VC2713.

Discusión

Los resultados muestran una concentración marcada de fallas y de tiempo de paro en pocas categorías y modelos, lo que refuerza la utilidad del análisis de Pareto como herramienta de priorización en mantenimiento.

La dominancia de problemas asociados al cabezal sugiere que este subsistema constituye el principal punto crítico en las máquinas analizadas.

Otro hallazgo relevante es el peso de los outliers en el tiempo de paro total. Aunque estos eventos no constituyen la mayoría de los registros, su capacidad para explicar una fracción sustancial del tiempo de paro indica que no deben ser tratados como simple ruido estadístico.

La evolución favorable de MTBF y MTTR sugiere una mejora simultánea de la confiabilidad y la mantenibilidad del sistema. En términos operativos, esto significa que las fallas ocurren con menor frecuencia y que, cuando ocurren, el sistema logra recuperarse en menos tiempo.

El análisis de la antigüedad de las máquinas aporta además una dimensión estratégica. La asociación observada entre mayor edad, mayor tiempo de espera y mayor coste de piezas sugiere un posible efecto de obsolescencia. Aunque el estudio no permite establecer causalidad, sí ofrece evidencia útil para orientar decisiones sobre renovación, sustitución o refuerzo de mantenimiento en determinados modelos.

Conclusión

El estudio permitió identificar las principales fuentes de falla y su impacto sobre el desempeño operativo de las máquinas de costura. Se comprobó que pocas categorías concentran la mayor parte de las fallas y del tiempo de paro, con un papel especialmente relevante de las fallas del cabezal. También se evidenció que los eventos extremos en el tiempo de paro, aunque menos frecuentes, explican una parte importante del impacto operativo total.

Los indicadores MTBF y MTTR mostraron una evolución favorable, lo que sugiere una mejora progresiva en la confiabilidad de los equipos y en la eficiencia del mantenimiento. Además, el análisis de antigüedad indicó que los modelos más antiguos tienden a asociarse con mayores horas de espera y mayores costes de piezas, lo que aporta evidencia útil para la priorización técnica y la toma de decisiones de renovación.

En general, el trabajo demuestra que el análisis de datos históricos de mantenimiento puede convertirse en una herramienta estratégica para priorizar intervenciones, optimizar recursos y apoyar decisiones basadas en evidencia.

Como recomendación práctica, se propone focalizar acciones en las fallas del cabezal, monitorear de forma específica los outliers de tiempo de paro, intervenir prioritariamente los modelos que frenan el MTBF global y evaluar la conveniencia de reforzar o renovar los equipos con mayor antigüedad y criticidad.

Referencias bibliográficas

- Armstrong, D. (2016). *The power of Pareto analysis in maintenance*. Reliable Plant.
- Illowsky, B., & Dean, S. (2023). *Introductory statistics* (2nd ed.). OpenStax, Rice University.

Society for Maintenance and Reliability Professionals. (s. f.). *Improving equipment reliability using PARETO analysis*.