

Análisis de fallas en máquinas de costura para optimizar el mantenimiento industrial

Exploración de datos, detección de anomalías y análisis de confiabilidad mediante MTBF/MTTR

Andrey Ismagilov

Contexto y problema

CONTEXTO

- Industria textil altamente dependiente de continuidad operativa
- +37M docenas de prendas al año para exportación
- Necesidad de optimizar mantenimiento y analizar causas de tiempo de inactividad

PROBLEMAS

- Fallas en equipos→ paros imprevistos
- Impacto en toda la línea de producción
- Pérdidas económicas y retrasos en las entregas

Objetivos

- Identificar causas de fallos
- Reducir tiempo de paro
- Optimizar mantenimiento

Fuentes de datos

- **Sistema EAM:** fallos de máquinas y órdenes de trabajo
- **Recursos Humanos:** antigüedad de los mecánicos
- **Registro de equipos:** edad de las máquinas de costura

Descripción del dataset

Unidad de análisis

- 1 registro = 1 fallo de máquina

Variables principales

- Identificación: equipment, base_model (categóricas)
- Fallas: problem_desc, failure_desc (categóricas)
- Mantenimiento: repair_hours, waiting_hours(numéricas), wo_type, mechanic
- Costes: parts_cost (numérica)
- Tiempo / Impacto: date, downtime_gross (numérica – tiempo total de parada)

Volumen de datos

~150.000 registros | 21 variables

Metodología

- Integración de datos: EAM, RR. HH. y antigüedad de máquinas
- Exploración y análisis de datos (EDA)
- Análisis de Pareto de fallos
- Cálculo de MTBF y MTTR
- Detección de anomalías


Herramientas utilizadas

- Python
- Pandas para manipulación de datos
- Scikit-learn para imputación con KNNImputer
- Matplotlib, Seaborn y Plotly Express para visualización


Análisis exploratorio

Total modelos: 119

Top 20 Modelos base con más número de fallas




Análisis exploratorio




Análisis exploratorio


Número de fallas por mes




Tiempo de paro por mes, horas



Análisis exploratorio




Análisis exploratorio



Análisis exploratorio


Antigüedad del mecánico vs Promedio de días entre fallas




Análisis exploratorio

Total de problemas: 24

Problemas de equipo ordenados por frecuencia




Análisis de Pareto por frecuencia de fallas



Top 2 problemas = 94% de las fallas.


Análisis de Pareto por Tiempo de paro




Top 2 problemas = 94% del Tiempo de paro.

Análisis de Pareto por tipo de falla


Total tipos de fallas: 38



Análisis de Pareto por tipo de fallo




Análisis de pareto por Tiempo de paro




Top 3 fallas = 82% del Tiempo de paro

EDA: evolución mensual de fallas por grupo de problema




EDA: evolución mensual de fallas por grupo de problema

Frecuencia de fallas por mes y grupo de problema




EDA: evolución mensual de los principales grupos de falla





EDA: evolución mensual por grupo de fallo (detalle)

Frecuencia de fallas por mes y grupo de fallas



Antes de calcular los indicadores **MTBF** y **MTTR**, se realizó un **análisis de valores atípicos en el tiempo de paro** para identificar eventos extremos que pudieran afectar la interpretación de los resultados.

Análisis de outliers en tiempo de paro (downtime_gross)




Detección de outliers

- Se utilizó el **rango intercuartílico (IQR)** para identificar valores atípicos.
- **Q1 = 29 min**
- **Q3 = 115 min**
- **IQR = 86 min**
- **Límite superior = 244 min (4 horas)**

Outlier si: **$\text{downtime_gross} > Q3 + 1.5 \times \text{IQR}$**


Análisis de outliers en Tiempo de paro (downtime_gross)

Impacto de Outliers en Tiempo de paro total



Análisis de outliers en Tiempo de paro (downtime_gross)


Impacto de Outliers en Tiempo de paro total por mes



Los outliers no son ruido, son eventos operativos relevantes


Modelos críticos según impacto de outliers

Análisis de Modelos: Cantidad vs. Impacto de Outliers
Número total de Modelos: 119




[Ver gráfico interactivo](#)

Pareto de modelos con mayor impacto de outliers




Indicadores fundamentales de desempeño operativo MTBF y MTTR

Tiempo Operativo (Up-time), Fuera de Servicio (Down-time), Para Falla y Entre Falla




KPIs de mantenimiento


Evolución Mensual del MTBF (Días entre Fallos)



Evolución Mensual del MTTR (Horas de Paro)




Top 10 modelos con menor confiabilidad (MTBF más bajo)



Matriz MTBF–MTTR


Matriz de Desempeño por Modelo Base



[Ver gráfico interactivo](#)


Análisis de obsolescencia: edad de la máquina vs horas de espera

Análisis de Obsolescencia: Edad vs Espera



Análisis de obsolescencia: edad de la máquina vs coste de piezas

Análisis de Obsolescencia: Edad vs Coste de piezas



Insights claves

- La mayor parte de las fallas se concentra en **pocas categorías críticas**, siguiendo un patrón de **Pareto**.
- Los problemas relacionados con el **cabezal de la máquina** son los más frecuentes y los que generan mayor tiempo de paro.
- Los **outliers** en tiempo de paro, aunque no son la mayoría de los casos, explican una parte importante del impacto operativo.
- Los KPIs muestran una mejora del sistema: **el MTBF aumenta y el MTTR disminuye** a lo largo del período analizado.
- Los modelos de mayor antigüedad tienden a presentar **mayores horas de espera y mayores costes de piezas**, lo que sugiere un posible efecto de **obsolescencia**.

Recomendaciones

- Priorizar fallas del **cabezal**
- Monitorear y reducir **outliers**
- Intervenir modelos **más críticos**
- Evaluar **renovación** de equipos antiguos
- Controlar **MTBF y MTTR** de forma continua

Conclusión

El análisis permitió **identificar fallas críticas, evaluar el desempeño del mantenimiento y apoyar decisiones de mejora basadas en datos.**

Próximos pasos y mejoras

- Desarrollo de modelos predictivos de fallas (Machine Learning)
- Predicción de fallos a 4 semanas (mantenimiento predictivo)

Gracias !